

Analisis Optimasi Portofolio Menggunakan Metode *Whale Optimization Algorithm* (WOA) dan *Grey Wolf Optimization* (GWO) dengan Pendekatan Analisis Klaster K-Means++ dan K-Medoid

(Studi Kasus: Saham Harian IDX80 Periode 7 Juli 2023 – 7 Juli 2024)

Amalia Nur Zahro¹, Marta Afifah², Rhizka Febrianty Aisyah Dewi³

^{1,2,3}Program Studi Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Gadjah Mada, Sekip Utara No.21, Bulaksumur, Yogyakarta, 55281, Indonesia

¹amalianurzahro@mail.ugm.ac.id ²martaafifah@mail.ugm.ac.id

³rhizkafebriantyaisyahdewi2004@mail.ugm.ac.id

Abstrak

Investasi di pasar saham menawarkan potensi keuntungan yang signifikan, tetapi juga diiringi dengan risiko yang tinggi. Untuk mengelola risiko ini, pembentukan portofolio optimal menjadi solusi penting, salah satunya dengan pendekatan Mean-Variance oleh Markowitz. Meskipun efektif, pendekatan ini memiliki keterbatasan dalam menangani distribusi *return* yang tidak normal dan keberadaan outlier. Oleh karena itu, penelitian ini mengintegrasikan algoritma *clustering* (K-Means++ dan K-Medoid) dengan algoritma optimasi berbasis *Swarm Intelligence*, yaitu *Whale Optimization Algorithm* (WOA) dan *Grey Wolf Optimization* (GWO), untuk membangun portofolio yang lebih adaptif dan optimal. Penelitian menggunakan data historis 80 saham dari indeks IDX80 selama periode 7 Juli 2023 hingga 7 Juli 2024. Analisis dimulai dengan pengelompokan saham berdasarkan *return* dan risiko menggunakan K-Means++ dan K-Medoid, yang masing-masing menghasilkan *silhouette score* tertinggi sebesar 0,62617 dan 0,53399 dengan 2 klaster. Dari setiap klaster, saham dengan *Sharpe Ratio* tertinggi dipilih sebagai representatif untuk analisis portofolio. Saham representatif K-Means++ adalah BRIS.JK dan AMMN.JK, sedangkan saham representatif K-Medoid adalah JSMR.JK dan AMMN.JK. Hasil penelitian menunjukkan bahwa metode GWO K-Means++ dan Mean-Variance K-Means++ adalah metode yang paling konsisten dengan kinerja terbaik dalam beberapa periode bulan, menjadikannya pilihan yang paling stabil untuk alokasi portofolio. Optimasi portofolio dengan algoritma *Swarm Intelligence* menunjukkan hasil yang kompetitif. Algoritma GWO menunjukkan kinerja unggul dalam aspek pembobotan dan kinerja portofolio, sedangkan WOA menawarkan variasi strategi yang adaptif terhadap struktur klasterisasi. Penelitian ini memberikan kontribusi pada pengembangan pendekatan kombinasi *clustering* dan algoritma *Swarm Intelligence* dalam optimasi portofolio saham. Integrasi ini memungkinkan seleksi aset yang lebih terstruktur dan efisien dalam menghadapi kompleksitas data pasar saham.

Keywords: Saham, Investasi, Portofolio, Clustering, K-Means++, K-Medoid, Swarm Intelligence, Whale Optimization Algorithm, Grey Wolf Optimization, Mean-Variance

1. PENDAHULUAN

Investasi di pasar saham menjadi salah satu instrumen yang banyak diminati oleh investor karena potensi keuntungan yang signifikan dalam jangka panjang. Namun, tingginya peluang keuntungan ini diiringi oleh risiko yang juga cukup tinggi. Oleh karena itu, investor cenderung membentuk portofolio yang terdiversifikasi guna mengurangi risiko yang melekat pada aset individu. Salah satu metode yang sering digunakan dalam pembentukan portofolio adalah pendekatan Mean-Variance yang diperkenalkan oleh Markowitz (1952). Model ini menawarkan cara untuk membangun portofolio optimal dengan menggabungkan berbagai aset berdasarkan tingkat *return* yang diharapkan dan risiko dalam bentuk variansi.

Namun, asumsi utama dari model Mean-Variance klasik adalah distribusi *return* saham bersifat normal dan tidak memiliki *outlier* yang signifikan. Pada kenyataannya, data pasar saham sering kali memiliki distribusi yang berbeda dari asumsi ini, serta terdapat anomali data seperti *outlier* yang dapat memengaruhi estimasi parameter dan menghasilkan portofolio yang tidak optimal. Oleh karena itu, diperlukan pendekatan baru yang lebih adaptif untuk menangani data pasar saham yang kompleks.

Untuk mengatasi tantangan ini, algoritma berbasis *Swarm Intelligence* (SI), yang terinspirasi dari perilaku kolektif sistem alami, muncul sebagai alat yang kuat dalam optimasi portofolio. Tidak seperti pendekatan evolusioner tradisional, algoritma SI meniru kecerdasan kolektif yang diamati di alam, seperti perilaku kawanan burung atau koloni semut, untuk secara efektif menavigasi ruang pencarian yang kompleks dalam optimasi portofolio. Dua algoritma SI yang digunakan dalam penelitian ini adalah *Whale Optimization Algorithm* (WOA) dan *Grey Wolf Optimization* (GWO).

Kombinasi algoritma WOA dan GWO dengan teknik *clustering* seperti K-Means++ dan K-Medoid memberikan pendekatan inovatif untuk seleksi aset yang lebih terstruktur sebelum optimasi. Dengan mengintegrasikan analisis *clustering*, penelitian ini bertujuan untuk mengidentifikasi aset yang relevan berdasarkan dinamika harga yang mendasarinya, sebelum mengalokasikan bobot portofolio menggunakan algoritma SI.

2. TINJAUAN PUSTAKA

2.1 Portfolio

Portofolio adalah sekumpulan aset (Husnan, 2005). Menurut Tandelillin (2001), portofolio adalah kombinasi atau gabungan sekumpulan aset baik berupa *real assets* maupun *financial assets* yang dimiliki investor. Portofolio dibentuk untuk mengurangi risiko dengan cara diversifikasi, yaitu mengalokasikan sejumlah dana pada berbagai alternatif investasi. Misal, ingin dibentuk portofolio dari p aset. *Return* portofolio adalah rata-rata terboboti dari setiap aset, yaitu:

$$r_{port} = w_1 r_1 + \dots + w_p r_p = w^T r \quad (1).$$

Maka, *expected return* dan varian portofolio adalah (Supandi dkk, 2014):

$$E[r_{port}] = w_1 \mu_1 + \dots + w_p \mu_p = w^T \mu \quad (2)$$

$$Var[r_{port}] = Var(w_1 r_1 + \dots + w_p r_p) = w^T \Sigma w \quad (3)$$

dengan,

w_i : bobot aset ke- i , $i = 1, 2, \dots, p$

r_i : *return* aset ke- i , $i = 1, 2, \dots, p$

μ_i : *expected return* aset ke- i , $i = 1, 2, \dots, p$

σ_i^2 : variansi aset ke- i , $i = 1, 2, \dots, p$

σ_{ij} : kovariansi aset ke- i dan aset ke- j , $i, j = 1, 2, \dots, p$

2.2 Clustering

Clustering atau klasterisasi adalah salah satu algoritma statistika pengelompokan data. Menurut Tan (2006), *clustering* adalah sebuah proses untuk mengelompokkan data ke dalam beberapa klaster atau kelompok sehingga data dalam satu klaster memiliki tingkat kemiripan yang maksimum dan data antar klaster memiliki kemiripan yang minimum. Analisis klaster digunakan untuk menemukan pola dalam data deret waktu keuangan. Suatu algoritma klaster berbasis jarak Euclidean terbukti memiliki kinerja lebih baik dibandingkan dengan algoritma klaster lainnya berdasarkan dataset, siklus pengujian, dan durasi waktu. Penerapan metode klasterisasi dalam pengurangan dimensi atau pra-pemrosesan model portofolio dapat meningkatkan kinerja model optimisasi. Pada penelitian ini, digunakan dua jenis metode klaster pada tahap pra-seleksi portofolio, yaitu K-means++ dan K-Medoid.

2.2.1 K-Means++

K-Means++ merupakan pengembangan dari algoritma K-Means yang berfokus pada penyebaran pusat klaster dengan memilihnya secara iteratif. Asumsi dasar algoritma ini adalah bahwa titik data yang terpisah jauh cenderung berasal dari klaster yang berbeda. Dalam hal ini, jarak terdekat titik objek ke pusat klaster terdekat atau centroid didefinisikan $D(x)$. *Centroid* dihitung dengan memilih $x \in x_j$ berdasarkan probabilitas berikut.

$$\frac{D(x)^2}{\sum_{x \in x_j} D(x)^2}$$

Kemudian, algoritma K-means diterapkan untuk meminimalkan fungsi objektif yang dinyatakan dengan persamaan berikut.

$$SSE(C) = \sum_{k=1}^K \sum_{x_j \in C_k} \|x_j - C_k\|^2$$

Dimana C_k adalah jumlah klaster yang dibentuk dari metode K-Means, dan x_j adalah variabel ke- j .

2.2.2 K-Medoid

Algoritma K-Medoid memiliki kesamaan dengan K-Means, yaitu keduanya bertujuan untuk meminimalkan fungsi objektif yang telah ditentukan. Namun, berbeda dengan K-means yang meminimalkan jumlah kesalahan kuadrat (SSE), K-Medoid meminimalkan kesalahan absolut karena K-Medoid lebih fokus pada pengurangan jarak antara titik data dan medoid masing-masing klaster. Fungsi objektif K-Medoid dapat dinyatakan dengan persamaan berikut.

$$S = \sum_{L=1}^L \sum_{x_j \in C_L} |x_j - med_{Lj}|$$

Dimana C_k adalah jumlah kluster yang dibentuk dari algoritma K-Medoid, dan med_{Lj} adalah medoid dari kluster C_L .

2.3 Mean-Variance

Metode Mean-Variance adalah salah satu metode sederhana yang dapat digunakan untuk perhitungan portofolio saham. Pembentukan portofolio optimal dengan menggunakan model *Mean Variance* (MV) diperkenalkan oleh Markowitz (1952). Teori ini menekankan pada penggunaan *mean* sebagai tingkat keuntungan yang diharapkan, sedangkan *variance* mengukur risiko (Supandi dkk, 2014). Portofolio model MV dirumuskan sebagai berikut:

$$\max_w w^T \mu - \frac{1}{2} \gamma w^T \Sigma w \quad (4)$$

$$kendala w^T e = 1 \quad (5)$$

dengan w menyatakan bobot portofolio, μ adalah vektor mean, Σ adalah matriks variansi-kovariansi, e adalah matriks kolom dengan semua elemennya adalah 1, dan $\gamma \geq 0$ adalah parameter penghindaran risiko (*risk aversion*), yaitu ukuran relatif penghindaran risiko. Ketika γ kecil (keengganan investor akan risiko dikategorikan rendah), mengakibatkan portofolio lebih berisiko. Sebaliknya, ketika γ bernilai besar (keengganan investor akan risiko tinggi) akan dihasilkan portofolio dengan risiko yang kecil (Supandi dkk, 2014).

Permasalahan optimasi pada persamaan (4) dan (5) dapat diselesaikan dengan menggunakan metode Lagrange. Dibentuk fungsi lagrange:

$$L = w^T \mu - \frac{1}{2} \gamma w^T \Sigma w + \lambda (w^T e - 1) \quad (6)$$

Berdasarkan teorema Kuhn-Tucker (Winston dan Goldberg, 2004), syarat perlu persamaan mencapai nilai optimum adalah:

$$\frac{\partial L}{\partial w} = 0 \quad (7) \quad \text{dan} \quad \frac{\partial L}{\partial \lambda} = 0 \quad (8)$$

Dari persamaan (6), (7), dan (8) diperoleh:

$$w = \Sigma^{-1} \left(\frac{\mu + \lambda e}{\gamma} \right) \quad (9)$$

$$e^T w = 1 \quad (10)$$

Substitusi persamaan (9) ke persamaan (10), diperoleh:

$$\lambda = \gamma (e^T \Sigma^{-1} e)^{-1} - (e^T \Sigma^{-1} e)^{-1} e^T \Sigma^{-1} \mu \quad (11)$$

Substitusi persamaan (11) ke persamaan (9), diperoleh:

$$w = \frac{\Sigma^{-1}}{\gamma} (\mu + (\gamma(e^T \Sigma^{-1} e)^{-1} - (e^T \Sigma^{-1} e)^{-1} e^T \Sigma^{-1} \mu) e)$$


$$w = \frac{1}{\gamma} (\Sigma^{-1} \mu + \gamma \Sigma^{-1} e (e^T \Sigma^{-1} e)^{-1} - \Sigma^{-1} e (e^T \Sigma^{-1} e)^{-1} e^T \Sigma^{-1} \mu)$$

$$w = \frac{1}{\gamma} (\Sigma^{-1} - \Sigma^{-1} e (e^T \Sigma^{-1} e) e^T \Sigma^{-1}) \mu + \Sigma^{-1} e (e^T \Sigma^{-1} e)^{-1} (12)$$

Persamaan (12) menunjukkan bahwa bobot portofolio (w) bergantung pada input vektor mean μ dan matriks variansi-kovariansi Σ .

2.4 Whale Optimization Algorithm (WOA)

Whale Optimization Algorithm (WOA) adalah algoritma optimasi metaheuristik yang terinspirasi dari perilaku berburu paus bungkuk (*humpback whales*). Algoritma ini didasarkan pada strategi perburuan yang dikenal sebagai *bubble-net feeding*. Metode *bubble-net feeding* paus bungkuk melibatkan dua gerakan utama, yaitu *upward-spirals* (gerakan spiral ke atas) dan *double-loops* (lingkaran ganda). *Double-loops* terdiri dari tiga tahap, yaitu *coral loop* (membentuk lingkaran), *lobtail* (memukul air dengan ekor), dan *capture loop* (menangkap mangsa). Dalam WOA, lokasi mangsa diasumsikan sebagai solusi terbaik saat ini. Dalam WOA, perilaku ini dimodelkan secara matematis untuk menyelesaikan masalah optimasi. Lokasi mangsa dianggap sebagai solusi terbaik sementara, dan paus lainnya memperbarui posisinya untuk mendekati solusi terbaik tersebut.



Gambar 1. Bubble-Net Feeding Paus Bungkuk

Tahap pertama dalam WOA adalah proses mengelilingi mangsa, yang dapat dinyatakan secara matematis sebagai berikut:

$$d = |\vec{c} \cdot \vec{w}_p^*(t) - \vec{w}(t)|$$

$$\vec{w}(t+1) = \vec{w}_p^*(t) - \vec{A} \cdot \vec{d}$$

Dimana $\vec{w}^*(t)$ adalah vektor solusi terbaik sementara, dan $\vec{w}(t)$ adalah vektor posisi paus. Vektor \vec{A} dan \vec{c} dihitung menggunakan rumus berikut.

$$\vec{A} = 2 \cdot \vec{a} \cdot \vec{r} - \vec{a}$$

$$\vec{c} = 2 \cdot \vec{r}$$

Dimana \vec{r} adalah vektor acak dalam interval $[0,1]$, dan \vec{a} adalah parameter yang menurun secara linear dari 2 ke 0 selama iterasi.

Tahap kedua, yaitu serangan terhadap mangsa (*bubble-net attack*), memadukan dua mekanisme: *shrinking encircling* dan *spiral updating position*. Pada tahap ini, paus dapat bergerak dalam lingkaran mengecil atau mengikuti jalur spiral dengan probabilitas masing-masing sebesar 50%. Model matematisnya adalah sebagai berikut: berikut:

$$\vec{w}(t+1) = \begin{cases} \vec{w}^*(t) - \vec{A} \cdot \vec{d}, & \text{jika } p < 0.5 \\ (\vec{w}^*(t) - \vec{w}(t)) \cdot e^{bl} \cdot \cos(2\pi l) + \vec{w}^*(t), & \text{sebaliknya} \end{cases}$$

Dimana p adalah angka acak dalam interval $[0,1]$, b adalah konstanta untuk mendeskripsikan spiral logaritmik, dan l adalah angka acak dalam interval $[-1, 1]$.

Tahap ketiga, yaitu pada fase eksplorasi, teknik serupa berdasarkan variasi vektor \vec{A} digunakan untuk mencari mangsa baru dalam pencarian global. Model matematis untuk eksplorasi adalah sebagai berikut.


$$d = |\vec{c} \cdot \overrightarrow{w_{rand}} - \vec{w}|$$

$$\vec{w}(t+1) = \overrightarrow{w_{rand}} - \vec{A} \cdot \vec{d}$$

Dimana $\overrightarrow{w_{rand}}$ adalah vektor posisi acak dari paus yang dipilih secara acak dari populasi paus yang ada.

2.5 Grey Wolf Optimization (GWO)

Algoritma *Grey Wolf Optimizer (GWO)* merupakan algoritma yang terinspirasi oleh perilaku berburu serigala di alam. Serigala abu-abu dianggap sebagai predator puncak, yang berarti bahwa serigala abu-abu berada di puncak rantai makanan. Serigala abu-abu juga memiliki hirarki dominan sosial yang tinggi. Para pemimpin yang merupakan tingkatan pertama akan disebut sebagai alfa, tingkatan kedua yaitu beta, tingkatan ketiga yaitu delta, sementara tingkatan terakhir yaitu omega. Selain hirarki sosial serigala, berburu secara berkelompok adalah perilaku menarik lain dari serigala abu-abu. Menurut Muro, dkk., fase utama berburu serigala abu-abu adalah pelacakan, mengejar, mendekati, dan mengacau mangsa sampai berhenti bergerak lalu menyerang mangsa. Adapun secara rinci perilaku serigala abu-abu dalam berburu dibagi kedalam beberapa tahapan yaitu, melingkari mangsa, berburu, menyerang mangsa (eksploitasi) dan menyerang mangsa (eksplorasi). Seperti disebutkan diatas, serigala abu-abu mengelilingi mangsanya selama berburu.



Gambar 2. Social hierarchy of Grey wolves

Adapun model matematisnya adalah sebagai berikut,

$$D = |C \cdot X_p(t) - X(t)| \quad (1)$$

$$X(t + 1) = X_p(t) - A \cdot D \quad (2)$$

Vektor A dan C dihitung mengikuti,

$$A = 2a \cdot r_1 - a \quad (3)$$

$$C = 2a \cdot r_2 \quad (4)$$

Sementara untuk berburu, model matematisnya adalah sebagai berikut

$$D_\alpha = |C_\alpha \cdot X_p - X|, D_\beta = |C_\beta \cdot X_p - X|, D_\delta = |C_\delta \cdot X_p - X| \quad (5)$$

$$X_1 = X_\alpha - A_\alpha \cdot (D_\alpha), X_2 = X_\beta - A_\beta \cdot (D_\beta), X_3 = X_\delta - A_\delta \cdot (D_\delta) \quad (6)$$

$$X(t + 1) = \frac{X_1 + X_2 + X_3}{3} \quad (7)$$

2.6 Sharpe Ratio

Sharpe ratio dapat digunakan untuk mengukur kinerja portofolio saham. Jika *sharpe ratio* digunakan untuk mengukur kinerja portofolio, *return* dan risiko yang digunakan adalah *return* dan risiko portofolio. Secara umum, semakin besar nilai *sharpe ratio* suatu portofolio saham, maka kinerja portofolio saham semakin baik. Sharpe (1994) menyatakan bahwa *sharpe ratio* dihitung dengan membandingkan selisih antara return portofolio (R) dan return risk-free (Rf) dengan standar deviasi return portofolio (σ) atau dapat ditulis sebagai berikut:

$$S_p = \frac{R - R_f}{\sigma}$$

3. METODE PENELITIAN

3.1 Deskripsi Data

Data historis yang digunakan mencakup harga penutupan harian saham. Data ini diperoleh dari Yahoo Finance sebagai salah satu sumber data pasar saham terpercaya yang menyediakan informasi lengkap mengenai harga saham dari waktu ke waktu. Sebanyak 80 saham digunakan dalam penelitian ini berasal dari daftar indeks IDX80 untuk periode data dari 7 Juli 2023 hingga 7 Juli 2024. Untuk menganalisis portofolio *performance* digunakan data dari bulan Agustus, September, Oktober, dan November tahun 2024.

3.2 Tahapan Analisis

Tahapan analisis yang akan digunakan antara lain

- Mengumpulkan data historis harga penutupan saham yang akan digunakan
- Menghitung nilai *return* saham
- Menghitung nilai *sharpe ratio*, *mean return*, dan standar deviasi dari masing-masing saham
- Melakukan *clustering* data saham berdasarkan *mean return* dan standar deviasi. Metode *clustering* yang digunakan yaitu metode *clustering* Kmeans++ dan K-

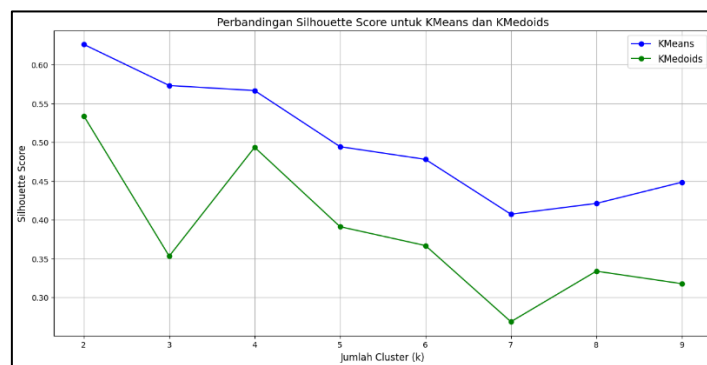
medoid. Penentuan jumlah *cluster* menggunakan *silhouette score*. Kemudian perwakilan saham dipilih untuk masing-masing metode.

- Melakukan optimisasi portofolio pada saham yang mewakili hasil dari *clustering* metode-metode yang digunakan sebelumnya. Algoritma optimisasi yang digunakan yaitu *Whale Optimization Algorithm (WOA)*, *Grey Wolf Optimization (GWO)*, dan *Mean Variance*.
- Melakukan analisis portofolio *performance*. Semakin tinggi nilai *sharpe ratio*, maka akan semakin bagus.

4. HASIL DAN PEMBAHASAN

4.1 Analisis Klaster

Dilakukan analisis klaster pada saham-saham IDX80 untuk menentukan saham yang akan digunakan dalam analisis portofolio. Jumlah klaster optimal untuk K-Means++ dan K-Medoid ditentukan menggunakan *silhouette score* sebagai metrik evaluasi.



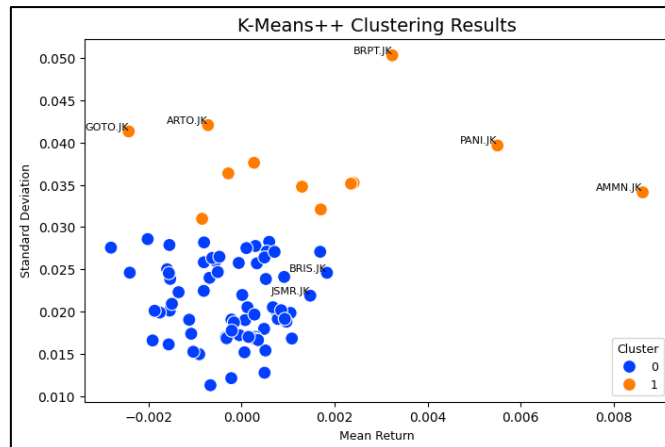
Gambar 3. Perbandingan *Silhouette Score* K-Means++ dan K-Medoid

Tabel 1. *Silhouette Score* Tertinggi K-Means++ dan K-Medoid

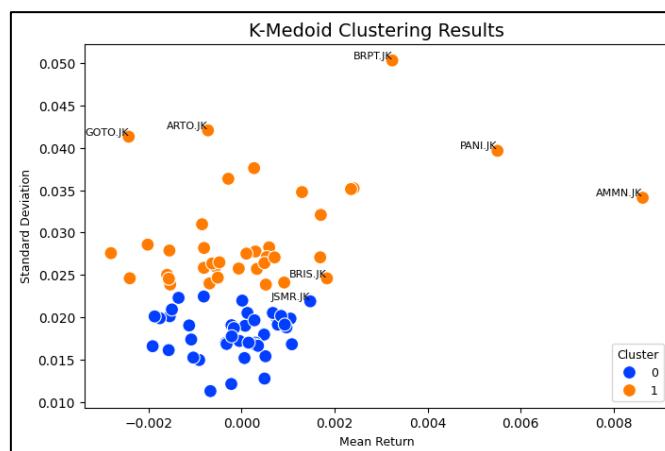
Metode	<i>Silhouette Score</i> Tertinggi
K-Means++	0,62617
K-Medoid	0,53399

Berdasarkan Gambar 1, dapat dilihat bahwa metode K-Means++ menghasilkan *silhouette score* yang lebih tinggi dibandingkan dengan metode K-Medoid. *Silhouette score* yang lebih tinggi pada K-Means++ menunjukkan bahwa klaster yang dihasilkan lebih jelas dan terpisah dengan baik dibandingkan klaster yang dihasilkan oleh K-Medoid. *Silhouette score* tertinggi untuk masing-masing metode tercapai saat jumlah klaster adalah 2, dengan nilai sebesar 0,62617 untuk K-Means++ dan 0,53399 untuk K-Medoid. Berdasarkan hasil ini, jumlah klaster optimal untuk kedua metode tersebut adalah 2 klaster.

Jumlah klaster optimal yang diidentifikasi sebelumnya digunakan untuk mengelompokkan 80 saham berdasarkan *return* dan standar deviasi. Berikut adalah hasil klaster yang terbentuk:



Gambar 4. Hasil Klaster K-Means++



Gambar 5. Hasil Klaster K-Medoid

Tabel 2. Profil Klaster K-Means++ dan K-Medoid

Metode	Jumlah Klaster	Klaster	Frekuensi	<i>Return (X)</i>	Standar Deviasi (Y)
K-Means++	2	0	68	-0,000238	0,021166
		1	12	0,001761	0,037464
K-Medoid	2	0	42	-0,000149	0,018116
		1	38	0,000294	0,029684

Profil klaster yang dirangkum dalam Tabel 2, menunjukkan karakteristik *risk-return* yang berbeda untuk metode K-Means++ dan K-Medoid. Karakteristik klaster dapat dianalisis dengan melihat *centroid* tiap-tiap klaster, yang mewakili *return* dan standar deviasi saham dalam setiap klaster. Nilai setiap *centroid* untuk setiap klaster memberikan wawasan tentang profil *risk-return* klaster.

Dalam kasus analisis K-Means++, terdapat dua klaster yang terbentuk. Klaster 1 mencakup 12 saham yang menunjukkan profil *high risk-high return*, yang ditandai dengan rata-rata *return* yang lebih tinggi (0,001761), tetapi juga disertai dengan standar deviasi yang lebih tinggi (0,037464). Sebaliknya, Klaster 0 mencakup 68 saham yang

menunjukkan profil *low risk-low return* dengan rata-rata *return* lebih rendah (-0,000238) dan standar deviasi yang lebih rendah (0,021166).

Analisis kluster dengan pendekatan K-Medoid juga terbentuk dua kluster. Kluster 1 mencakup 38 saham yang menunjukkan profil *high risk-high return*, yang ditandai dengan rata-rata *return* yang lebih tinggi (0,000294), tetapi juga disertai dengan standar deviasi yang lebih tinggi (0,029684). Sebaliknya, Kluster 0 mencakup 42 saham yang menunjukkan profil *low risk-low return* dengan rata-rata *return* lebih rendah (-0,000149) dan standar deviasi yang lebih rendah (0,018116).

Selanjutnya, akan dipilih satu saham dengan *sharpe ratio* tertinggi untuk tiap-tiap kluster dari masing-masing metode. Berikut adalah saham yang terpilih untuk digunakan dalam analisis optimasi portofolio:

Tabel 3. Saham yang Terpilih untuk Analisis Portofolio

Metode	Kluster 0	Kluster 1
K-Means++	BRIS.JK	AMMN.JK
K-Medoid	JSMR.JK	AMMN.JK

4.2 Optimasi Portofolio

Berdasarkan Tabel 3, diketahui bahwa saham yang terpilih untuk analisis portofolio adalah data saham BRIS.JK dan AMMN.JK mewakili kluster K-Means++ serta saham JSMR.JK dan AMMN.JK mewakili kluster K-Medoid. Selanjutnya, dilakukan optimisasi portofolio untuk menentukan bobot optimal setiap saham representatif dengan tujuan untuk meminimalkan risiko portofolio dan memaksimalkan return yang disesuaikan dengan risiko.

Tabel 4. Pembobotan Portofolio Saham

Kluster	Saham	Mean-Var	WOA	GWO
K-Means++				
0	BRIS.JK	0,65765	0,71212	0,65767
1	AMMN.JK	0,34235	0,28788	0,34239
K-Medoid				
0	JSMR.JK	0,70480	0,79084	0,70158
1	AMMN.JK	0,29520	0,20916	0,29845

Analisis terhadap bobot portofolio saham yang disajikan dalam Tabel 4 memberikan wawasan mengenai strategi alokasi portofolio dari dua model SI, yaitu WOA dan GWO dibandingkan dengan model tradisional Mean-Var. Perbedaan rata-rata absolut dalam penugasan bobot digunakan untuk mengukur sejauh mana kesesuaian antara model SI dan Mean-Var.

Pada kluster K-Means++, GWO dan Mean-Var menunjukkan kesesuaian yang paling dekat, dengan perbedaan bobot yang sangat kecil, yaitu hanya 0,00002 (0,65767 untuk GWO dan 0,65765 untuk Mean-Var pada saham BRIS.JK) dan 0,00004 (0,34239 untuk GWO dan 0,34235 untuk Mean-Var pada saham AMMN.JK). Ini menunjukkan

bahwa GWO menghasilkan alokasi portofolio yang hampir identik dengan yang diperoleh dari model Mean-Var pada klaster ini.

Sementara itu, WOA menunjukkan perbedaan bobot yang lebih besar, yaitu 0,05447 (0,71212 untuk WOA dan 0,65765 untuk Mean-Var pada saham BRIS.JK) dan 0,05453 (0,28788 untuk WOA dan 0,34235 untuk Mean-Var pada saham AMMN.JK). Ini mengindikasikan bahwa WOA memiliki strategi alokasi yang lebih berbeda dibandingkan dengan model Mean-Var dalam klaster ini.

Pada klaster K-Medoid, GWO juga menunjukkan kesesuaian yang paling dekat dengan Mean-Var, dengan perbedaan bobot yang kecil, yaitu 0,00322 (0,70480 untuk Mean-Var dan 0,70158 untuk GWO pada saham JSJR.JK) dan 0,00325 (0,29520 untuk Mean-Var dan 0,29845 untuk GWO pada saham AMMN.JK). Hasil ini mendukung gagasan bahwa GWO abila dipadukan dengan klasterisasi K-Medoid dapat menjadi alternatif yang baik untuk model Mean-Var dalam hal alokasi bobot.

Selain itu, WOA pada K-Medoid juga menunjukkan perbedaan bobot yang lebih besar. Pada saham JSJR.JK, perbedaan bobot antara WOA dan Mean-Var adalah 0,08604 (0,79084 untuk WOA dan 0,70480 untuk Mean-Var), dan pada saham AMMN.JK, perbedaannya adalah 0,08584 (0,20916 untuk WOA dan 0,29520 untuk Mean-Var). Ini menunjukkan bahwa strategi alokasi WOA dalam klaster K-Medoid lebih berfokus pada diversifikasi risiko dan imbal hasil yang lebih terdistribusi, berbanding dengan model Mean-Var yang lebih konservatif dalam distribusi bobotnya.

Secara keseluruhan, hasil analisis dalam penelitian ini menekankan bahwa meskipun model SI (WOA dan GWO) menggunakan mekanisme optimisasi yang berbeda, alokasi bobot yang dihasilkan tetap secara umum sebanding dengan model Mean-Var. Variasi dalam penugasan bobot antara berbagai model SI mencerminkan pendekatan unik dalam menyeimbangkan risiko dan imbal hasil, serta sensitivitas mereka terhadap struktur klaster yang dihasilkan oleh K-Means++ dan K-Medoid.

4.3 *Portofolio Performance*

Untuk mengevaluasi lebih lanjut implikasi dunia nyata dari portofolio optimal yang diteliti sebelumnya, penulis melakukan analisis kinerja portofolio untuk empat bulan ke depan dari periode data historis yang dianalisis sebelumnya yaitu bulan Agustus, September, Oktober dan November tahun 2024.

Tabel 5. *Performance* Portofolio Saham

Metode	Agustus 2024	September 2024	Oktober 2024	November 2024
GWO K-Means++	-1.053	-1.032	-0.882	-0.588
GWO K-Medoid	-1.167	-2.885	-0.874	-0.892
Mean-Var K-Means++	-1.053	-1.032	-0.882	-0.588
Mean-Var K-Medoid	-1.165	-2.882	-0.870	-0.885
WOA K-Means++	-1.064	-1.340	-0.843	-0.561
WOA K-Medoid	-1.132	-2.781	-0.783	-0.721

Analisis *performance* portofolio pada empat bulan tersebut disajikan pada Tabel 5. Metode dengan nilai *sharpe ratio* tertinggi menjadi metode yang paling baik estimasinya. Pada bulan Agustus dan September metode GWO K-Means++ dan Mean-Variance K-Means++ menjadi metode dengan nilai *sharpe ratio* tertinggi. Sedangkan pada bulan Oktober metode WOA K-Medoid menjadi metode dengan nilai *sharpe ratio* tertinggi dan pada bulan November, WOA K-Means++ menjadi metode dengan nilai *sharpe ratio* tertinggi. Jika dilihat dari semua metode dalam empat bulan keseluruhan, metode dengan nilai *sharpe ratio* tertinggi terbanyak dari masing-masing periode yaitu Metode GWO K-means++ dan metode Mean-Variance K-means++ dimana kedua metode tersebut memiliki nilai *sharpe ratio* yang sama pada tiap periode bulannya.

5. KESIMPULAN

Penelitian ini memberikan pendekatan sistematis untuk analisis portofolio saham dengan mengintegrasikan algoritma *clustering* dan algoritma optimasi berbasis *Swarm Intelligence* (SI). Dari analisis yang telah dilakukan sebelumnya, diperoleh kesimpulan sebagai berikut.

1. K-Means++ menghasilkan *silhouette score* tertinggi sebesar 0,62617 untuk 2 klaster, dengan saham representatifnya adalah saham BRIS.JK dan AMMN.JK.
2. K-Medoid menghasilkan *silhouette score* sebesar 0,53399 untuk 2 klaster, dengan saham representatifnya adalah saham JSJR.JK dan AMMN.JK.
3. Algoritma GWO menghasilkan alokasi portofolio yang hampir identik dengan yang diperoleh dari model Mean-Var, baik pada K-Means++ maupun K-Medoid sehingga hal ini menjadikan GWO alternatif yang baik untuk pendekatan tradisional.
4. Metode GWO K-Means++ dan Mean-Variance K-Means++ adalah metode yang paling konsisten dengan kinerja terbaik dalam beberapa periode bulan, menjadikannya pilihan yang lebih stabil untuk alokasi portofolio.
5. Penggunaan pendekatan swarm intelligence, khususnya GWO, mampu menghasilkan alokasi bobot dan performa yang mendekati atau setara dengan model tradisional Mean-Var, menjadikannya alternatif yang layak dalam portofolio modern.

Secara umum, hasil ini menunjukkan bahwa GWO merupakan metode yang kompetitif, baik dalam aspek pembobotan maupun kinerja portofolio, sedangkan WOA menawarkan variasi strategi yang adaptif tergantung pada struktur klasterisasi. Kombinasi model SI dengan teknik klasterisasi yang tepat dapat meningkatkan efisiensi dan hasil alokasi portofolio.

DAFTAR PUSTAKA

- Abdurakhman, M., Putra, M. N. H. T., & Purnaningrum, E. (2024). Clustering performance analysis in portfolio optimization based on the swarm intelligence algorithm. *IAENG International Journal of Computer Science*, 51(12), 1943–1949.
- Husnan, S. (2005). *Dasar-dasar Teori Portofolio dan Analisis Sekuritas*. Edisi ke 4. UPP AMP YKPN. Yogyakarta
- Mirjalili, S., & Lewis, A. (2014). Grey Wolf Optimizer, *Advances in Engineering Software* 69, 46-61.

- Mirjalili, S., & Lewis, A. (2016). The Whale Optimization Algorithm. *Advances in Engineering Software*, 95, 51–67. doi: 10.1016/j.advengsoft.2016.01.008.
- Muro, C., Escobedo, R., Spector, L. dan Coppinger, R. (2011). Wolf-pack (Canis lupus) hunting strategies emerge from simple rules in computational simulations, *Behav Process*, 88 : 192-7.
- GeeksforGeeks. (2021). *Grey wolf optimization – Introduction*. <https://www.geeksforgeeks.org/grey-wolf-optimization-introduction/>
- GeeksforGeeks. (2021). *Whale Optimization Algorithm (WOA)*. <https://www.geeksforgeeks.org/whale-optimization-algorithm-woa/>
- Rudianto, R. D., & Wijayanto, A. W. (2023). Analisis Perbandingan K-Means dan K-Medoids dalam Pengelompokan Provinsi Berdasarkan Indeks Demokrasi Indonesia 2021. *Komputika: Jurnal Sistem Komputer*, 13(1), 19-27. <https://doi.org/10.34010/komputika.v13i1.10812>
- Supandi, E.D., Anggara, Y. (2023). Analisis Klaster dalam Pembentukan Portofolio Robust Mean-Variance. *Jurnal Sains Matematika dan Statistika*, 9(1), 37–47. DOI: <https://dx.doi.org/10.24014/jsms.v9i1.19003>
- Supandi, E.D., Rosadi, D., dan Abdurakhman. (2014). Penerapan Estimasi Fast-MCD dan SOCP dalam Pembentukan Portofolio Robust Mean Variance. *E-Journal Unisba*, 14(1), 41–50.
- Tandelilin, E. (2001). Analisis Investasi dan Manajemen Portofolio Edisi Pertama. Yogyakarta: BPFE Yogyakarta.